Proyecto final: Predicción del éxito académico en educación superior

Maite Viejo Baena
2º iMAT
Aprendizaje automático
Mayo 2026

1 Introducción

Este documento expone el trabajo de Maite Viejo Baena, alumna de la Escuela Técnica Superior de Ingeniería (ICAI) de la Universidad Pontificia de Comillas. Dicho trabajo tiene como título "Proyecto Final: Predicción del éxito académico en educación superior" y se ha realizado en la asignatura de Aprendizaje automático de 2º de iMAT.

Este documento explorará la documentación de las decisiones de diseño y la estructura de los módulos. Además, analizará los resultados obtenidos con las distintas técnicas de ML aplicadas con el objetivo de sacar conclusiones sobre los factores que influyen a la trayectoria académica del alumnado.

2 Limpieza de datos

Antes de entrenar los modelos se exploró la estructura del dataset, comprobando la calidad de los daros, los tipos de variables y la presencia de posibles inconsistencias. El objetivo de este preprocesado fue adaptar la información a los algoritmos utilizados, con la intención de reducir ruido y evitar transformaciones que alteraran de manera innecesaria la información original. Las mejoras realizadas han intentado mejorar la interpretabilidad de los resultados y evitar posibles problemas de fuga de información.

2.1 Variables numéricas

En cuanto a las variables numéricas, tras comprobar que no existieran valores nulos explícitos, se observó que no fue necesario aplicar imputación. Se ha decidido mantener las variables académicas originales, pues, aunque algunas relaciones poco intuitivas como haber muchos casos en los que hay más asignaturas evaluadas qeu matriculadas podría deberse a criterios administrativos. Para los modelos sensibles a la escala, como regresión lineal, Lasso, ElasticNet, PCA y KMeans, las variables numéricas se estandarizaron para que todas contribuyeran de forma equilibrada. En cambio, en Random Forest no se aplicó escalado, ya que los modelos basados en árboles no dependen de la magnitud de las variables.

Además, se analizó la correlación entre variables. Como se puede observar en la figura 1, todas aquellas variables sobre los semestres tienen una alta correlación entre ellas. Muy alta con aquellas que son del mismo semestre y también alta entre las variables de distintos cuatrimestres. Sin embargo, se decidió no eliminar ninguna de ellas pues todas muestran información distinta que puede ser útil para el entrenamiento de los modelos.

Preprint.

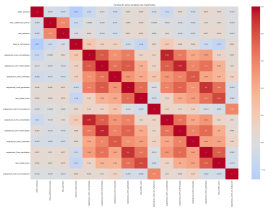


Figure 1: Correlaciones entre variables numéricas

2.2 Variables categóricas

En cuanto a las variables categóricas, se ha requerido de un procesamiento más específico pues había un número elevado de categorías y una distribución muy desbalanceada. Mantener todas las categorías habría podido producir muchas variables binarias al aplicar one-hot encoding, aumentando la dimensionalidad y con alto riesgo de introducir ruido.

Por este motivo, se decidió agrupar algunas de las categorías poco frecuentes siguiendo criterios semánticos. En las variables estado_civil, modo_solicitud, cualificacion_previa, cualificacion y ocupacion de los progenitores, las categorías iniciales se reorganizaron de forma más general y fácil de interpretar. En cuanto a cualificación de los progenitores se agrupó por nivel educativo, manteniendo un cierto criterio de tipos de estudio por 'dificultad', mientras que las ocupaciones se agruparon por capacidad adquisitiva que estos pueden generar. Estas agrupaciones han permitido mantener la información relevante de cada variable a la vez que reducir una fragmentación excesiva de los datos.

Por otro lado, las categorías de en_blanco o desconocido se ha decidido mantener pues formaban parte de un porcentaje notable del dataset, es decir, la ausencia de la información podía ser excesiva, eliminando datos útiles.

Por último, la variable nacionalidad se ha decidido eliminar pues estaba muy desbalanceada y aportaba información redundante con respecto a la variable internacional

3 Modelo de clasificación

La primera tarea del proyecto consistió en construir un modelo de clasificación supervisada para predecir la situación final del estudiante entre tres clases: abandono, matriculado y graduado. Se trata de un problema multiclase cuyo objetivo principal es analizar si las variables personales, académicas, socioeconómicas y administrativas permiten anticipar la trayectoria final del alumnado.

3.1 Selección de variables y preprocesado

Antes de entrenar el modelo, se separó la variable objetivo del resto de predictores. Posteriormente, el conjunto de datos se dividió en entrenamiento y test, reservando un 20% de las observaciones para la evaluación final. Esta división se realizó de forma estratificada, ya que la variable objetivo presentaba un desbalanceo moderado: la clase más frecuente era graduado, seguida de abandono y, por último, matriculado. La estratificación permitió mantener proporciones similares de cada clase en ambos subconjuntos.

Las variables categóricas se transformaron mediante one-hot encoding, ya que el modelo Random Forest no puede trabajar directamente con variables de tipo texto. Esta codificación se ajustó únicamente sobre el conjunto de entrenamiento y posteriormente se aplicó al conjunto de test, evitando así utilizar información procedente del conjunto de evaluación durante el preprocesado. Además, se conservaron las variables numéricas originales y se concatenaron con las variables categóricas codificadas. Las variables numéricas se mantuvieron en su escala original, puesto que los modelos basados en árboles no requieren estandarización.

3.2 Random Forest Classifier

Como modelo principal se utilizó Random Forest Classifier. Esta elección se justifica porque es un modelo adecuado para datos tabulares, permite capturar relaciones no lineales y puede manejar interacciones entre variables sin necesidad de especificarlas manualmente.

Para evaluar el modelo no se utilizó únicamente accuracy, sino también el F1 macro. Esta métrica es especialmente adecuada en este problema porque calcula el rendimiento medio dando el mismo peso a cada clase, independientemente de su frecuencia. De este modo, se evita que la evaluación quede dominada por la clase mayoritaria.

Para la selección del modelo se compararon distintas configuraciones de Random Forest, variando el número de árboles y la profundidad máxima mediante validación cruzada estratificada. Además, se comparó un modelo base con una versión que utilizaba class_weight="balanced", con el objetivo de comprobar si penalizar más los errores en las clases minoritarias mejoraba el rendimiento, especialmente en la clase matriculado.

Los resultados mostraron que el Random Forest base obtuvo un rendimiento ligeramente superior al modelo balanceado. En concreto, el modelo base alcanzó una accuracy de 0.772 y un F1 macro de 0.696, mientras que el modelo balanceado obtuvo una accuracy de 0.765 y un F1 macro de 0.685. Por tanto, se seleccionó como modelo final el Random Forest base, ya que ofrecía el mejor equilibrio entre rendimiento global y rendimiento medio por clase.

3.3 Análisis de los resultados

El modelo final obtuvo una accuracy de 0.772, lo que indica que clasifica correctamente aproximadamente el 77% de los estudiantes del conjunto de test. Sin embargo, al tratarse de un problema multiclase con cierto desbalanceo, es necesario analizar también las métricas por clase.

La clase mejor predicha fue graduado, con una precisión de 0.77, un recall de 0.93 y un F1-score de 0.84. Esto significa que el modelo identifica correctamente una proporción muy elevada de los estudiantes que finalmente se gradúan. Este resultado es esperable, ya que se trata de la clase mayoritaria y, además, las variables académicas contienen información muy relevante para distinguir a los estudiantes con mejor trayectoria.

La clase abandono obtuvo también un rendimiento alto, con una precisión de 0.85, un recall de 0.75 y un F1-score de 0.79, indicando que el modelo es capaz de detectar una parte importante de los estudiantes que abandonan, aunque no consigue identificar algunos casos.

Por último, la clase más difícil de clasificar fue matriculado, con una precisión de 0.59, un recall de 0.36 y un F1-score de 0.45. Aunque estos resultados mejoran respecto a versiones anteriores del modelo, siguen mostrando que el estado matriculado es el más problemático. Esto puede explicarse porque es la clase menos representada en el dataset, y porque es una categoría intermedia: estos estudiantes no han abandonado, pero tampoco se han graduado, por lo que pueden compartir características con ambas clases.

Esto se puede observar en la matriz de confusión 3, sugiriedo que la frontera entre matriculado y el resto de situaciones académicas no está tan claramente definida a partir de las variables disponibles.

3.4 Importancia de las variables

Una vez entrenado el modelo final, se analizó la importancia de las variables proporcionada por el Random Forest. Para ello, se utilizaron las importancias internas del modelo, asociando correctamente cada valor de importancia con las columnas finales empleadas en el entrenamiento, es decir, tanto las variables numéricas originales como las variables categóricas codificadas mediante one-hot encoding.

Este análisis permite identificar qué variables han tenido mayor peso en las decisiones del modelo. En general, las variables académicas y de trayectoria del estudiante aparecen entre las más relevantes, lo cual es coherente con el problema planteado: el rendimiento previo y la información académica disponible aportan una señal importante para anticipar la situación final del alumnado. También aparecen variables relacionadas con el curso, el modo de solicitud y determinadas características administrativas o socioeconómicas, sugiriendo que la trayectoria académica no depende únicamente del rendimiento, sino también del contexto de acceso y de las condiciones del estudiante.

Estos resultados deben entenderse como asociaciones útiles para la predicción y no como efectos directos sobre la trayectoria académica.

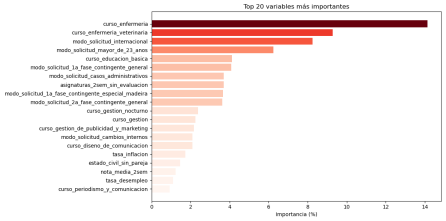


Figure 2: Importancia de variables

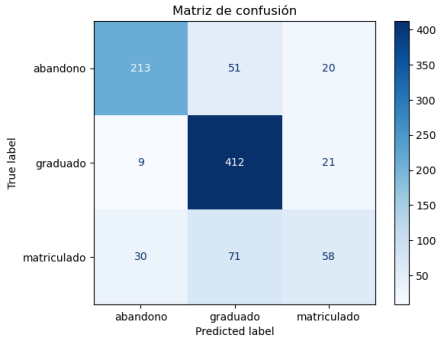


Figure 3: Matriz de confusión

3.5 Conclusión

En conclusión, el modelo Random Forest ofrece un rendimiento global razonablemente alto para la tarea de clasificación multiclase. Se trata de un modelo especialmente eficaz identificando estudiantes graduados mostrando también un buen rendimiento en la clase abandono. Sin embargo, presenta mayores dificultades para clasificar correctamente a los estudiantes matriculados, debido tanto al menor número de ejemplos disponibles como al carácter intermedio de esta categoría.

Estos resultados muestran que las variables disponibles permiten anticipar parcialmente la trayectoria académica final del alumnado, aunque el modelo no debe interpretarse como una herramienta de decisión individual definitiva. Su utilidad principal sería servir como apoyo exploratorio para detectar patrones generales y posibles perfiles de riesgo, especialmente en relación con el abandono académico.

4 Modelo de regresión

La segunda tarea del proyecto consistió en construir modelos de regresión para predecir la variable nota_media_2sem, que reperesenta la calificación media obtenida por el estudiante en el segundo semestre.

4.1 Selección de variables

Antes de entrenar se hizo un selección cuidadosa de las variables para evitar posibles problemas de data leakage. En concreto se han eliminado todas aquellas variables relacionadas con el segundo semestre (asignaturas_2sem_**), la propia variable que se va a predecir (nota_media_2sem), pues contienen información relevante y muy cercana sobre el la variable que se va a predecir. Además, se eliminó la variable objetivo pues esta resume la situación final del estuante, pudiendo introducir información posterior sobre el rendimeitno del estudiante.

4.1.1 Variable objetivo

La variable objetivo presenta una distribución claramente asimétrica 4. En ella se puede observar una clara e importante aglomeración de estudiantes con una nota igual a cero, y otro grupo mayoritario con calificaciones situadas aproximadamente entre 10 y 14. Esto lo que nos muestra es que el modelo se ha de ajustar a dos casos muy distintos. Por este motivo se ha decidido evaluar los modelos combinando tres métricas distintas:

RMSE: porque penaliza especialemente los errores grandes

MAE: permite interpretar el error medio en unidades de nota

R^2: indica la proporción de la variabilidad de la variable objetivo explicada por el modelo

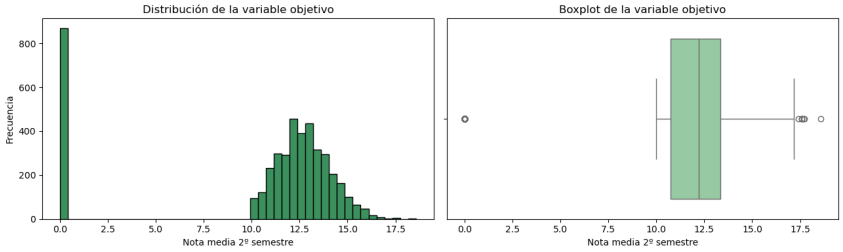


Figure 4: nota_media_2semestre

4.1.2 Regresión lineal

Como primer modelo se utilizó una regresión lineal sin regularización, que ha servido como modelo base. Para poder aplicarla, las variables categóricas se transformaron mediante one-hot encoding con drop="first", evitando multicolinealidad perfecta entre variables dummy. Además, las variables numéricas se estandarizaron, ya que los modelos lineales son sensibles a la escala de las variables y el escalado facilita una estimación más estable de los coeficientes. El conjunto de datos se dividió en entrenamiento y test, reservando un 20% de las observaciones para la evaluación final.

Este modelo obtuvo un RMSE de 2.759, un MAE de 1.631 y un R^2 de 0.724 en el conjunto de test. Esto nos indica que el modelo explica aproximadamente un 72% de la variabilidad de la nota media del segundo semestre, por tanto se puede interpretar que un modelo relativamente sencillo puede capturar una parte notable de la relación entre la variable de entrada y el rendimiento a posteriori. No obstante, el valor de la métrica MAE nos muestra que en el modelo existen desviaciones relevantes en algunas predicciones, especialmente en aquellos casos más extremos.

A continuación se entrenaron modelos lineales regularizados, en específico Lasso y ElasticNet. Para la selección de hiperparámetros se utilizó validación cruzada con 5 particiones. En particular, en el modelo de Lasso, el mejor valor de alpha fue 0.01, obteniendo un RMSE de 2.767, un MAE de 1.579 y un R^2 de 0.723. Por otro lado, ElasticNet cuenta con los parámetros alpha = 0.01 y l1_ratio = 0.5, obteniendo un RMSE de 2.761, un MAE de 1.586 y un R^2 de 0.724. En general, estos modelos muestran un rendimeinto muy parecido al modelo sin regularizar, sin mejorar de forma clara el RMSE y R^2. Esto lo que nos da a entender es que no existía un problema grave de sobreajuste en el modelo lineal base, auqneu regularizar puede aportar algo más de estabilidad al modelo.

4.1.3 Random Forest Regressor

Finalmente se entrenó un Random Forest Regressor para comparar el rendimiento de kos modelos lineales con un modelo no lineal. Para este caso se estandarizaron las variables numéricas, pues los modelos basados en árboles no dependen de la escala de los datos. En cuanto a los hiperparámetros, fueron seleccionados mediante validación cruzada, obteniendo la configuración: n_estimators = 300, max_depth = 10 y min_sample_leaf = 4. Este modelo alcanzó el mejor rendimento global con un RMSE de 2.616, un MAE de 1.369 y un R^2 de 0.752. La mejora que aporta este modelo frente a los lineales es debido a la existencia de relaciones no lineales entre variables que el resto de modelos no son capaces de capturar al completo.

4.1.4 Análisis de los resultados

En cuanto al análisis de residuos, el modelo final muestra que la mayor parte de los errores se concentran alrededor de cero, indicando que el modelo presenta un sesgo general muy marcado. Sin embargo, también se observan errores patrones en ciertos tramos de la variable objetivo. El error absoluto medio más elevado se encuentra en los estudiantes con nota media igual o cercana a cero, además de en los valores más bajos de rendimiento. Por otro lado, el modelo predice mejor aquellas calificaciones situadas entre 10 y 15, que son las más frecuentes en el dataset. Esto lo que muestra es que el modelo aprende mejor aquellos patrones que son mayoritarios, teniendo más dificultades en anticipar comportamientos extremos. 5

La importancia de las variables en Random Forest muestra que el primer semestre es el factor más relevante para predecir la nota del segundo semestre. En concreto, las asignaturas aprobadas

aparece como la variable más importante, seguida de la nota media y las asignaturas evaluadas. Este resultado es coherente desde el punto de vista académico, pues muestra que los estudiantes con mejor desempeño al principio, tienden a tener mejores resultados posteriormente. Las variables de contexto económico y administrativo, también aparecen pero tienen un menor peso relativo. 6

En conclusión, la tarea de regresión muestra que es posible anticipar parte importante del rendimiento académico del segundo semestre haciendo uso de la información previa del estudiante. Mientras que los modelos lineales muestran un rendimiento razonable, sinedo útiles como referencia interpretable, Random Forest Regressor obtiene los mejores resultados, prrobablemnete por su capacidad para modelar relaciones no lineales. No obstante, los errores en los valores extremos muestran una importante limitación, pues la predicción es más fiable para aquellos estudiantes con redimientos habituales que para casos de abandono o resultados muy bajos. Por lo tanto, los resultados se deberían de interpretar como una herramienta de apoyo y no como una predicción determinista del rendimeinto individual.

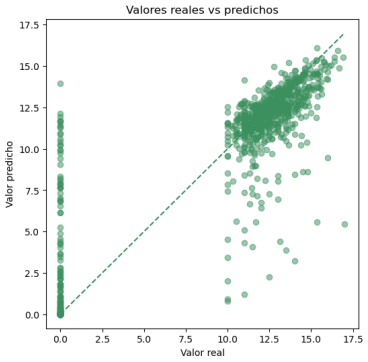


Figure 5: Variables reales vs. predichas

	Feature Importance
asignaturas_1sem_aprobadas	80.052632
nota_media_1sem	6.578156
asignaturas_1sem_evaluadas	1.629473
nota_admision	1.436098

Figure 6: Feature Importance

5 Modelo no supervisado

La tercera parte del proyecto consistió en aplicar técnicas de aprendizaje no supervisado con el objetivo de identificar perfiles de estudiantes a partir de sus características académicas, personales y socioeconómicas.

5.1 Selección de variables y preprocesado

Para esta tarea se probaron distintas selecciones de variables. En primer lugar, se consideró un conjunto amplio de variables académicas, incluyendo información del primer y segundo semestre. También se evaluó una variante que añadía variables macroeconómicas (tasa de desempleo, la inflación y el PIB). Sin embargo, estos modelos introducían redundancia y ruido en el proceso de agrupamiento. Muchas variables académicas estaban fuertemente correlacionadas entre sí e incluirlas podía hacer que KMeans diese demasiado peso al rendimiento académico, distorsionando las distancias entre estudiantes.

Finalmente, se seleccionó un conjunto simplificado de variables, buscando un equilibrio entre capacidad descriptiva e interpretabilidad. Las variables utilizadas fueron edad_al_matricularse, nota_admision, nota_cualificacion_previa, nota_media_1sem, nota_media_2sem, becado, deudor, matricula_al_dia y desplazado. Esta selección combina información académica previa, rendimiento universitario y algunos factores administrativos o socioeconómicos relevantes.

Las variables numéricas se estandarizaron antes de aplicar el modelo, evitando que la escala de las variables les proporcionara valores numéricos más grandes artificialemnete a las distancias Por otro lado, las variables categóricas se transformaron mediante one-hot encoding, evitando introducir un orden artificial entre categorías.

5.2 PCA y número de clusters

Como apoyo al análisis se aplicó PCA, con el objetivo de reducir la dimensionalidad y estudiar la estructura general de los datos. Mediante esta técnica, se ha podido resumir la información original conjunto más pequeño de componentes principales, facilitando la comparación entre modelos y la visualización de posibles agrupamientos.

Para seleccionar el número de clusters se utilizaron dos criterios: el método del codo y el índice de silueta. El método del codo permite analizar cómo disminuye la suma de distancias intra-cluster, mientras que la silueta mide hasta qué punto los estudiantes están bien asignados a su cluster en comparación con los demás. Aunque algunos valores mayores de k, especialmente $k = 6$, podían ofrecer una silueta ligeramente superior, se decidió seleccionar $k = 3$ como número final de clusters. Esta decisión se basó principalmente en criterios de interpretabilidad. Un número mayor de clusters fragmentaba demasiado los datos y generaba grupos difíciles de explicar desde un punto de vista educativo. En cambio, con tres clusters se obtenían perfiles claros y coherentes.

5.3 Interpretación de los clusters

Tras ajustar el modelo final con $k = 3$, se analizaron las características medias de cada cluster y su relación posterior con la variable objetivo, mostrando diferencias claras entre los grupos, especialmente en las variables de rendimiento académico.

El primer perfil corresponde a estudiantes con rendimiento académico intermedio. Este grupo presenta notas medias en el primer y segundo semestre en torno a 12 puntos y un número razonable de asignaturas aprobadas. Su distribución respecto a la variable objetivo es relativamente equilibrada, aunque con mayor presencia de estudiantes graduados. Aproximadamente el 54% de los estudiantes de este cluster terminan graduándose, mientras que las clases abandono y matriculado tienen pesos similares. Por tanto, se trata de un grupo mixto, formado por estudiantes con una trayectoria académica razonable pero no claramente diferenciada hacia el éxito o el abandono.

El segundo perfil representa a los estudiantes con mejor trayectoria académica. Este grupo muestra las notas de admisión y de cualificación previa más altas, así como las mejores calificaciones medias en el primer y segundo semestre. También presenta el mayor número medio de asignaturas aprobadas. En relación con la variable objetivo, este cluster concentra la mayor proporción de graduados, aproximadamente un 67%, y la menor proporción de abandonos. Este perfil puede interpretarse como el grupo de menor riesgo académico y mayor probabilidad de éxito.

El tercer perfil es el más claramente diferenciado y corresponde a estudiantes con alto riesgo académico. Presenta una edad media superior al resto y, sobre todo, un rendimiento muy bajo en ambos semestres. La nota media del primer semestre es cercana a 1.8 y la del segundo semestre se sitúa por debajo de 1, con un número medio de asignaturas aprobadas prácticamente nulo. Este comportamiento se refleja claramente en la variable objetivo: alrededor del 82% de los estudiantes pertenecen a la clase abandono. Por tanto, el modelo ha sido capaz de identificar un grupo de estudiantes con una trayectoria académica muy problemática.

Además de las variables estrictamente académicas, también aparecen diferencias relevantes en variables administrativas y socioeconómicas. El cluster de mayor riesgo presenta una proporción más baja de estudiantes becados, una mayor presencia de estudiantes deudores y una proporción claramente superior de estudiantes que no tienen la matrícula al día. Estos factores no deben interpretarse como causas directas del abandono, pero sí como señales asociadas a situaciones de mayor vulnerabilidad.

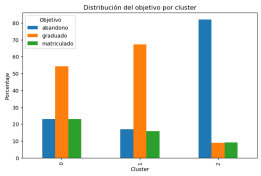


Figure 7: Distribución objetivo

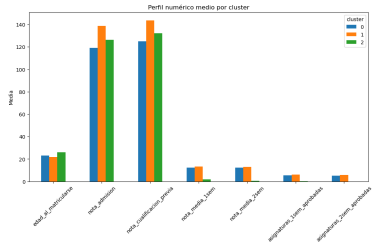


Figure 8: Perfil numérico

La tarea no supervisada permitió identificar tres perfiles de estudiantes con características diferenciadas. El resultado más relevante es la aparición de un grupo de alto riesgo, caracterizado por bajo rendimiento académico, menor proporción de becas, mayor presencia de deudas y peor situación administrativa, concentrando una alta proporción de estudiantes que abandonan los estudios, a pesar de que la variable objetivo no fue utilizada para construir los clusters.

Esto indica que las variables seleccionadas contienen información suficiente para descubrir estructuras relevantes en el alumnado. Además, los clusters obtenidos son interpretables y podrían ser útiles desde el punto de vista institucional, por ejemplo para diseñar estrategias de seguimiento académico o detectar perfiles que podrían beneficiarse de apoyo temprano.

6 Conclusiones finales y limitaciones

En este proyecto se han abordado tres tareas complementarias sobre el rendimiento y la trayectoria académica del alumnado: clasificación, regresión y aprendizaje no supervisado. En conjunto, los resultados muestran que las variables disponibles permiten extraer información relevante sobre el abandono, la graduación y el rendimiento académico.

En la tarea de clasificación, el modelo Random Forest obtuvo un rendimiento global razonablemente alto, con una accuracy de 0.772 y un F1 macro de 0.696. Este modelo fue especialmente eficaz identificando estudiantes graduados y obteniendo también buenos resultados en la clase abandono. Sin embargo, la clase matriculado fue la más difícil de clasificar, probablemente por ser la menos representada, mostrando que, aunque el modelo permite anticipar parcialmente la trayectoria final, todavía existen limitaciones para distinguir situaciones académicas menos definidas.

En la tarea de regresión, el objetivo fue predecir la nota media del segundo semestre evitando fuga de información. Para ello, se eliminaron las variables del segundo semestre y la variable de situación final del estudiante. Los modelos lineales ofrecieron un rendimiento razonable, pero el mejor resultado se obtuvo con Random Forest Regressor, alcanzando un R^2 de 0.752. Esto sugiere que existen relaciones no lineales entre las variables de entrada y el rendimiento académico posterior. Las variables más relevantes fueron las relacionadas con el rendimiento del primer semestre, confirmando la importancia del rendimiento inicial como indicador del futuro.

Por último, el análisis no supervisado permitió identificar tres perfiles diferenciados de estudiantes. Uno de ellos concentraba una proporción muy elevada de abandonos y se caracterizaba por bajo rendimiento académico y mayor presencia de problemas administrativos o económicos. Este resultado complementa las tareas supervisadas, ya que permite interpretar perfiles generales dentro del alumnado.

Como limitación principal, debe señalarse que los modelos identifican asociaciones, pero no relaciones causales. Por ejemplo, variables como la beca, la deuda o la matrícula al día pueden estar relacionadas con el abandono, pero no se puede afirmar que sean su causa directa. Además, algunas variables académicas del primer y segundo semestre contienen información muy cercana a la trayectoria final del estudiante, como consecuencia, se deben de utilizar con cuidado dependiendo de la predicción que se quiera realizar.

En conclusión, el proyecto muestra que el rendimiento académico temprano es el factor más informativo para anticipar tanto la nota posterior como la situación final del estudiante. Sin embargo, las variables socioeconómicas y administrativas también aportan información relevante para interpretar perfiles de riesgo.